

به نام خدا

**مبانی بینایی کامپیوتر**

**دکتر محمدی**

**تمرین سه**

علی عطاریان - ۹۹۵۲۱۴۵۱

### سوال (الف)

$$K = 1 - \max(R, G, B)$$


$$\begin{bmatrix} C \\ M \\ Y \end{bmatrix} = \begin{bmatrix} 1 - K \\ 1 - K \\ 1 - K \end{bmatrix} - \begin{bmatrix} R \\ G \\ B \end{bmatrix}$$

ابتدا مقادیر را نرمالایز کرده و سپس با توجه به فرمول روبرو پیاده‌سازی می‌کنیم:

نتیجه: `[0.31372549 0.23529412 0. 0.49019608]`




### سوال (ب)

در تابع `cv2.cvtColor` از فلگ‌های `cv2.COLOR_BGR2YCR_CB` و `cv2.COLOR_BGR2HSV` استفاده می‌کنیم



### سوال (ج)



ابتدا تصویر را به فضای HSV می‌بریم و حال کانال‌های این تصویر به ترتیب مقادیر  $H, S, V$  را نشان می‌دهند.



### سوال (۱) د

حالت خاکستری هر تصویر را به عنوان یکی از کانالهای یک تصویر RGB قرار می‌دهیم. تصویر ۱ را در کانالهای آبی و سبز و تصویر ۲ را در کانال قرمز قرار دادیم پس رنگ زرد مربوط به نقاط متمایز تصویر ۲ و رنگ آبی مربوط به نقاط متمایز تصویر ۱ می‌باشد.

در پیاده‌سازی به این مشکل برمی‌خوریم که دو تصویر ابعاد متفاوتی دارند. به همین دلیل باید از مینیمم طول و عرض استفاده کرد.



### سوال (۱) ه

۱. ادراک: برخی فضاها رنگی سعی می‌کنند درک انسان از رنگها را بازسازی کنند مانند فضای HSI. مثلاً انسان هنگام توصیف رنگ از عبارت (ترکیب قرمز و سبز) استفاده نمی‌کند بلکه به صورت (زرد روشن) بیان می‌کند که به مدل رنگ Hue، اشباع Saturation، شدت روشنایی Intensity نزدیکتر است

۲. پایداری نسبت به روشنایی: برخی مدلها مانند HSV نسبت به تغییرات شرایط نوری نامتغیر هستند پس برای کاربردهایی مثل یافتن اشیاء مناسب هستند.

۳. جدایی نور و روشنایی: فضاهایی مانند YCbCr طراحی شده‌اند که کانالهای نور و روشنایی در آنها جدا باشند که مناسب کاربردهایی مثل فشرده‌سازی ویدیو می‌باشد.

۴. بهینگی محاسباتی: فضاهایی مانند gray-scale یا binary color باعث افزایش سرعت محاسبات کامپیوتری در برخی کاربردها می‌شوند.

۵. کاهش هزینه‌ها: فضای رنگی‌ای مثل CMYK طراحی شده است که در هنگام چاپ تصاویر با رنگهای کمتر بتوان ترکیب‌های متنوع‌تری ایجاد کرد تا در هزینه رنگ صرفه‌جویی شود.

## سوال (۲)

ابتدا تصاویر را یکی‌یکی می‌خوانیم و در یک ردیف نشان می‌دهیم.



با دستور `cv2.Stitcher.create()` یک instance از آبجکت موردنظر را می‌سازیم. با استفاده از متد `stitch` تصاویر را به یکدیگر وصل می‌کنیم. این متد دو خروجی می‌دهد که یکی از آنها نشان می‌دهد آیا متد موفق به تشکیل تصویر شده است یا خیر و دومی تصویر خروجی است.




## سوال (۳)

توضیح تابع `put_mask`: ابتدا آبجکت `detector` را می‌سازیم که وظیفه‌اش تشخیص چهره‌ها در تصویر می‌باشد. سپس مدل یادگیری `dlib.shape_predictor` را با دیتاستی که دانلود کرده‌ایم آموزش می‌دهیم. این مدل وظیفه‌اش تشخیص نقاط کلیدی چهره است. در اینجا `face_rects = detector(gray_face, 1)` مستطیل‌هایی که دور چهره‌ها کشیده شده‌اند (در این مسئله یک مستطیل) را دریافت می‌کنیم. پارامتر دوم ورودی نشان‌دهنده تعداد لایه‌هایی است




که برای upscale کردن تصویر استفاده می‌شود. هرچه این عدد بیشتر باشد یعنی امکان یافتن تصاویر بیشتر است اما هزینه محاسباتی بالا می‌رود. با توجه به مسئله فعلی ۱ لایه کافی است. حال نقاط کلیدی هر چهره را دریافت می‌کنیم و آن را برای آسانی از تایپ آبجکت به np.array تبدیل می‌کنیم. فور لوپ منطقی در اینجا لازم نبود اما بدون آن درست کار نمی‌کرد! ۴ لندمارک مربوط به چهره و عکس را با آزمون و خطای بسیار زیاد به دست می‌آوریم. باید توجه داشت که از np.float32 حتما استفاده شود. تابع cv2.getPerspectiveTransform با نقاط کلیدی منبع و مقصد ماتریس تبدیل را می‌سازد و سپس با تابع cv2.warpPerspective تبدیل را روی منبع انجام می‌دهیم. به پارامتر size دقت شود که به ترتیب (عرض، طول) باشد. سپس برای قرار دادن ماسک روی صورت، از آنجایی که نقاط بدون ماسک در تصویر خود ماسک سیاه هستند از cv2.bitwise\_or استفاده می‌کنیم.


face



result



dotted\_face

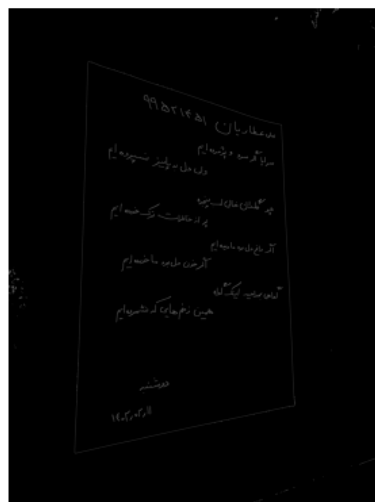


قسمت show landmarks on face فقط برای visualize کردن بهتر پیاده‌سازی شده است که ۶۸ نقطه کلیدی چهره را نشان می‌دهد.

## سوال (۴) الف)


برای نویزگیری از `bilateralfiltering` استفاده می‌کنیم چون در عین کم کردن نویز تصویر را محو نمی‌کند (برعکس فیلترهایی مانند فیلترگوسی که ممکن است باعث شود جزئیاتی را از دست بدهیم مخصوصا در متن). برای لبه یابی از `canny` استفاده می‌کنیم چون لبه‌های دقیق‌تر و نازک‌تر می‌دهد و برای ادامه کار مثل پیدا کردن کانتور راحت‌تر هستیم. همچنین لبه‌یاب `sobel` جواب خاکستری برمی‌گرداند و `binary-color` نیست که برای ورودی `findContours` نامناسب است. پارامترهای `cv2.bilateralFilter` به ترتیب تصویر ورودی، سایز فیلتر، سیگما در فضای رنگی، سیگما در فضای مختصاتی می‌باشد. هر چه سیگمای رنگی بیشتر باشد، رنگهایی دورتر از رنگ پیکسل موردنظر با آن ترکیب می‌شوند (در صورتی که همسایه پیکسل باشند) و هر چه سیگمای مختصاتی بیشتر باشد، پیکسلهایی دورتر همدیگر را تحت تاثیر قرار می‌دهند (به شرطی که رنگشان اندازه کافی شبیه باشد). در کل با زیاد شدن هر کدام ۳ پارامتر عددی وارد شده، خروجی `smooth` تر می‌شود. مقداری را انتخاب کردیم که بین حذف نویز و حذف جزئیات تعادل برقرار شود. پارامترهای ورودی `cv2.canny` را در داک تمرین ۲ توضیح داده‌ایم:

“پارامترهای تابع `cv2.canny` به ترتیب تصویر ورودی، `minValue` و `maxValue` هستند. مقادیر بالاتر از `maxValue` حتما لبه هستند و مقادیر کمتر از `minValue` حتما لبه نیستند اما مقادیر بین این دو اگر به نقاط لبه (نقاط با مقدار بیش از `maxValue`) وصل باشند آنگاه لبه حساب می‌شوند.” با آزمون و خطا متوجه می‌شویم مقادیر ۶۰ و ۹۰ لبه‌ها را به خوبی می‌یابند.



#### سوال ۴ (ب)

کانتورها را پیدا می‌کنیم، با توجه به وجود متن در تصویر کانتورهای زیادی یافت می‌شوند اما بزرگترین کانتور نشان‌دهنده کاغذ است، آن را پیدا کرده و در پس‌زمینه سیاه نشان می‌دهیم.

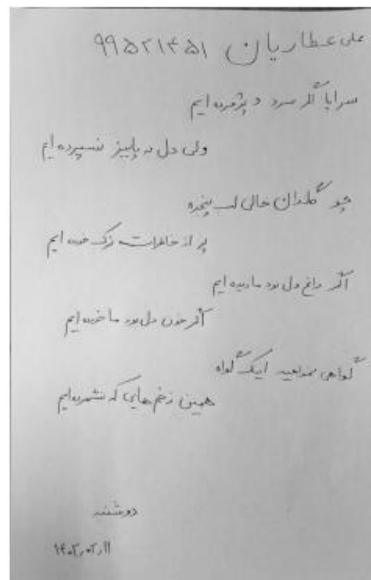


#### سوال ۴ (ج)

ابتدا باید چهار نقطه گوشه کاغذ را بیابیم تا آنها را به چهار گوشه تصویر نهایی مپ کنیم. ابتدا کانتور کاغذ را به یک چندضلعی تخمین می‌زنیم. در ابتدای پیاده‌سازی به علت اپسیلون بسیار کم یکی از گوشه‌ها پیدا نمی‌شد اما با آزمون و خطا متوجه می‌شویم مقدار  $0.05$  کمترین اپسیلونی است که گوشه سمت راست بالا را برمی‌گرداند. اما حال `cv2.approxpolyDP` بیشتر از ۴ نقطه برمی‌گرداند. می‌دانیم نقاط با بالاترین و پایین‌ترین ارتفاع به ترتیب نقاط سمت چپ بالا و سمت چپ پایین هستند. همچنین نقطه با ارتفاع نزدیک به نقطه سمت چپ بالا، نقطه سمت راست بالا می‌باشد و نقطه با ارتفاع نزدیک به نقطه سمت چپ پایین، نقطه سمت راست پایین است. بر این اساس تابع `get_corners` را می‌نویسیم که ۴ نقطه را برگرداند.

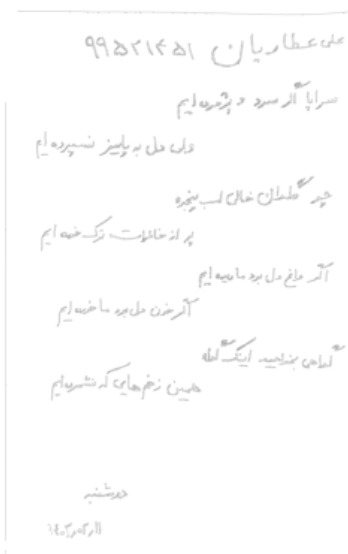


با داشتن این نقاط می توان تابع تبدیل را گرفت و تبدیل را انجام داد.



#### سوال (۴) (د)

برای بهبود کیفیت تصویر باید کنتراست بین متن و کاغذ را زیاد کنیم تا متن بهتر جلوه کند پس ابتدا از کلاسه استفاده می کنیم. سپس به علت نویز زیاد یکبار نویزگیری می کنیم. حال تصویر را به فضای باینری می بریم تا فقط متن دیده شود. از کنی استفاده می کنیم اما چون پس زمینه سیاه است به کمک `cv2.threshold` و لیبل `cv2.THRESH_BINARY_INV` پس زمینه را سفید می کنیم.





## سوال (۵ الف)

الگوریتم هریس برای شناسایی گوشه‌ها در تصویر است که برپایه شناسایی ناحیه‌هایی است که در آنها تغییر در تمام جهت‌ها رخ می‌دهد. ابتدا با عملگر سوبل مشتق‌های افقی و عمودی را در فضای grayscale به دست می‌آوریم. سپس توان دو مشتق‌ها و حاصلضرب آنها را محاسبه کرده و

چنین ماتریسی تشکیل می‌دهیم.

$$\begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$




سپس یک پنجره برای تاثیر همسایه‌های محلی در نظر می‌گیریم که می‌تواند گوسی یا مستطیلی باشد (معمولا مستطیلی است). در نهایت با اعمال چنین فرمولی روی تک‌تک پیکسل‌ها و حذف مقادیر غیربیشینه (non-maximum suppression) گوشه‌ها با مقادیر روشن (سفید) یافت می‌شوند.

$$R = \det(M) - k(\text{trace}(M))^2$$



مقدار  $k$  در حساسیت الگوریتم تاثیرگذار است به طوری که هرچه بیشتر باشد، حساسیت بالاتر است. معمولا مقداری است بین ۴ تا ۶ درصد.

## سوال (۵ ب)

مطابق الگوریتم ابتدا مشتق افقی و عمودی را با سوبل به دست می‌آوریم. سپس توان دو و حاصلضرب مشتقات را حساب می‌کنیم. حال پنجره مستطیلی را روی این سه مقدار (که در واقع ماتریسی به اندازه ابعاد تصویر هستند) اعمال می‌کنیم. مقدار  $R$  را می‌یابیم. حال مقادیر غیربیشینه را حذف می‌کنیم. در این فرایند هر پیکسلی که مقدارش از آستانه تعیین شده (یک درصد ماکسیمم) و ۸ همسایه‌اش بیشتر باشد ۱ می‌شود و باقی پیکسل‌ها صفر. در نهایت صرفا جهت اطمینان جواب پیش و پس از حذف مقادیر غیربیشینه را برمی‌گردانیم تا نمایش دهیم. برای نمایش بهتر نقاط سفید که بسیار کوچک هستند از `cv2.dilate` که نقاط روشن را گسترش می‌دهد.



برای استفاده از تابع آماده `opencv` ابتدا تصویر را خاکستری کرده و سپس پارامترهای اندازه پنجره هریس (در نظر گرفتن همسایه‌ها)، سایز فیلتر سوبل و  $k$  را به عنوان ورودی به `cv2.cornerharris` می‌دهیم. مشاهده می‌کنیم خروجی مشابهی تولید شد.



## سوال ۶)

الگوریتم Scale-invariant Feature Transform ابتدا با استفاده از Difference of Gaussian اکستریم های محلی را شناسایی می کند. DoG بدین صورت عمل می کند که یک ورژن از عکس که توسط فیلتر گاوسی بلار شده است را از یک ورژن کمتر بلار شده منها می کند. سپس به هر کدام از این لوکال اکستریم ها یک جهت گیری اختصاص داده می شود که با استفاده از گرادیانت خود و همسایه هایش به دست می آید. سپس یک همسایگی  $16 \times 16$  از هر نقطه کلیدی به  $4 \times 4$  بلاک تقسیم می شود که هر بلاک  $4 \times 4$  جهت گیری در ۸ جهت را نشان می دهد یعنی جمعا ۱۲۸ ویژگی. پس هر نقطه کلیدی با ۱۲۸ ویژگی توصیف می شود.

الگوریتم Speeded-Up Robust Feature نسخه سریع تر SIFT است. این الگوریتم به جای DoG از فیلترهای جعبه ای استفاده می کند که بسیار سریع تر می باشند زیرا فیلترهای کوچکتری از فیلتر گاوسی هستند و از مقادیر ساده ای مثل  $-1$  و  $+1$  استفاده می کنند. برای تشخیص جهت گیری نیز از Haar-Wavelet استفاده می کند که در واقع روشی بر اساس مشتق گیری است. سپس یک همسایگی  $20 \times 20$  از هر نقطه به  $16 \times 16$  ناحیه  $4 \times 4$  تقسیم می شود که هر ناحیه  $4 \times 4$  مقدار (مشتق افقی و عمودی و قدر مطلق آنها) را نشان می دهد. پس جمعا ۶۴ ویژگی برای هر نقطه کلیدی تولید می کند.

الگوریتم Orientated FAST and Robust BRIEF جدیدترین الگوریتم از میان این ۳ می باشد. این الگوریتم ابتدا با استفاده از FAST نقاط کلیدی را شناسایی می کند. FAST نقاط کلیدی را بر اساس مقایسه شدت روشنایی یک پیکسل با همسایه اش در یک ناحیه دایروی پیدا می کند (گوشه ها را تشخیص می دهد). سپس جهت گیری را با استفاده از intensity centroid method شناسایی می کند که از یک ناحیه دایروی استفاده می کند تا جهت کلی را به دست آورد. سپس از BRIEF استفاده می کند تا یک توصیف binary برای هر نقطه کلیدی به دست آورد. این الگوریتم جفت پیکسل ها را مقایسه می کند و بر اساس نسبت مقادیر آنها یک رشته دوتایی تولید می کند. ORB از آنجایی که جهت گیری را شناسایی کرده، می داند کدام جفت پیکسل ها را به BRIEF و این باعث بهبود performance می شود.

الگوریتم ORB از دو الگوریتم دیگر سریعتر است اما نسبت به تغییر اندازه (scale) پایدار نیست و به محو بودن و نویز بیشتر حساس است. این الگوریتم در محاسبه تقریباً ده برابر از دوتای دیگر سریعتر است و بیش از ۳ برابر نقاط کلیدی استخراج می‌کند. در شناسایی نقاط کلیدی یکسان در تصاویری که چرخیده‌اند یا تغییر در روشنایی داشته‌اند ۳ الگوریتم عملکرد نسبتاً مشابهی داشته‌اند. در مقایسه مختصات نقاط کلیدی تصویر ترنسفورم شده و تصویر اصلی، SIFT به‌طور متوسط ۲۰ پیکسل خطا می‌کند. SURF و ORB در حدود صفر. نتیجه‌گیری اینکه سریع‌ترین الگوریتم ORB است با اینکه دو الگوریتم دیگر کاربردهای خود را دارند.